IS 794 DEEP LEARNING FINAL PROJECT REPORT

ODD SEMESTER ACADEMIC YEAR 2026/2027
INFORMATION SYSTEM STUDY PROGRAM
FACULTY OF ENGINEERING AND INFORMATICS
UNIVERSITAS MULTIMEDIA NUSANTARA

Project of Week:
7
Group Name and Class:
Group 06 / IS 794-C
Member (Name / NIM):
1. Christian Zoe Beru Tena - 00000108336 2. Kelvin Alexander - 00000106797 3. Valentino Candako Hardi - 00000107746 4. Alfonsus Ronaldy Hidayat – 00000112181 5. Bimo Sekti Mahardika - 00000126658
Project Title
Perbandingan Model Pre-trained HuBERT dan Wav2Vec 2.0 untuk Klasifikasi Musik Tradisional Berdasarkan Asal Daerah dalam Mendukung Pelestarian Budaya Indonesia
Background (100 – 500 words) *Include: problem(s), purpose, method(s)*

Musik tradisional Indonesia merupakan warisan budaya takbenda (*intangible cultural heritage*) yang sangat bernilai tinggi dan mencerminkan kekayaan identitas etnis di seluruh wilayah Nusantara. Namun, eksistensi musik daerah kini menghadapi tantangan pelestarian dan marginalisasi akibat arus globalisasi, dominasi industri musik populer modern, serta minimnya dokumentasi arsip audio digital yang terstruktur rapi. Sebagian besar rekaman lagu daerah yang beredar di ruang digital belum memiliki metadata wilayah asal dan karakteristik musikal yang terstandarisasi. Upaya identifikasi dan pengelompokan daerah asal musik secara manual membutuhkan waktu yang panjang, bergantung pada keahlian etnomusikologi yang terbatas, serta rentan terhadap subjektivitas pendengar karena kemiripan instrumen, ritme, maupun penggunaan sistem tangga nada tradisional non-diatonis (seperti laras *pelog* dan *salendro*) [1], [7].

Untuk menjawab permasalahan tersebut, penelitian ini bertujuan membangun sistem komputasi cerdas berbasis *Deep Learning* yang mampu mengklasifikasikan rekaman musik tradisional Indonesia secara otomatis berdasarkan klaster wilayah budaya asalnya guna membantu katalogisasi dan pencarian arsip budaya digital. Secara khusus, penelitian ini bertujuan menguji dan membandingkan secara empiris efektivitas dua arsitektur fondasi *Self-Supervised Learning* (SSL) audio mutakhir, yaitu **HuBERT (Hidden-Unit BERT)** [4] dan **Wav2Vec 2.0** [5], dalam mengekstraksi representasi laten dari sinyal musik tradisional.

Metodologi penelitian dirancang menggunakan kerangka kerja standar **CRISP-DM (Cross-Industry Standard Process for Data Mining)** dari tahap pemahaman domain budaya hingga pembuatan prototipe *deployment*. Pendekatan pemodelan bertumpu pada *transfer learning* [6] dari model pralatih SSL yang di-*fine-tune* langsung menggunakan gelombang suara mentah satu dimensi (*1D raw waveform*) 16 kHz mono berdurasi 5 detik

(80.000 sampel) tanpa bergantung pada reduksi fitur manual statis. Dataset primer dikumpulkan dan dikurasi secara mandiri dari YouTube sebanyak 855 rekaman lagu daerah (~61,28 jam) lintas 38 provinsi yang dipetakan ke dalam 7 klaster wilayah budaya regional (Sumatera, Jawa, Bali–Nusa Tenggara, Kalimantan, Sulawesi, Maluku, dan Papua), menghasilkan 78.074 segmen audio bebas kebocoran data (*anti-data leakage*) [8], [9].

Literature Study and Previous Work

Include: state-of-the-art, related previous works/articles from most recent international journals (minimum 5)

State of the Art (Perkembangan Mutakhir Klasifikasi Audio & Musik Tradisional):

Perkembangan riset *Music Information Retrieval* (MIR) dan pengenalan musik tradisional telah mengalami evolusi metodologis dalam tiga generasi utama. **Generasi pertama** mengandalkan rekayasa fitur akustik secara manual (*hand-crafted features*) yang merepresentasikan tekstur *timbre*, ritme, dan *pitch*—seperti *Mel-Frequency Cepstral Coefficients* (MFCC), *Zero Crossing Rate* (ZCR), *Spectral Centroid*, dan *Chroma*—yang diringkas menjadi statistik rata-rata dan simpangan baku lalu diklasifikasikan menggunakan algoritma klasik seperti *Support Vector Machine* (SVM) [7], [10]. Meskipun efisien secara komputasi, perataan statistik sepanjang waktu mereduksi dinamika melodi dan artikulasi transien instrumen etnik.

Generasi kedua beralih pada representasi visual waktu–frekuensi dua dimensi (seperti *Mel-Spectrogram* dan *Constant-Q Transform* / CQT) yang dipadukan dengan jaringan saraf konvolusional (*Convolutional Neural Network* / CNN) serta mekanisme *Attention* [1], [2], [11]. Pendekatan fusi multi-fitur dan CNN pralatih visual mampu menangkap pola lokal spektrogram dengan baik, namun sangat bergantung pada ketepatan parameter resolusi jendela STFT/Mel serta membutuhkan data berlabel dalam jumlah besar.

Generasi ketiga (Current State of the Art) memanfaatkan paradigma *Self-Supervised Learning* (SSL) dan arsitektur *Transformer* [3], [4], [5]. Model fondasi audio mempelajari struktur akustik laten secara mandiri dari ribuan jam rekaman tanpa label melalui mekanisme *masked prediction* atau *contrastive learning* langsung dari gelombang suara mentah (*1D raw waveform*). Melalui *transfer learning* [6], bobot pralatih seperti **Wav2Vec 2.0** [5] dan **HuBERT** [4] dapat diadaptasi (*fine-tuned*) pada dataset musik tradisional yang jumlah rekaman induknya terbatas dan mengalami ketimpangan kelas [8], dengan protokol evaluasi ketat untuk menghindari bias kebocoran data [9].

Kajian Penelitian Terdahulu (Related Previous Works):

1. Hsu dkk. (2021) — Arsitektur Fondasi HuBERT [4]: Mengembangkan *Hidden-Unit BERT* (HuBERT) yang mempelajari representasi audio secara *self-supervised* dengan memprediksi target unit diskrit hasil klasterisasi *k-means* pada segmen gelombang suara yang di-*masking*. Pendekatan ini mengatasi kelemahan kuantisasi kontinu karena memaksa lapisan Transformer mempelajari struktur akustik dan konteks urutan jangka panjang secara bersamaan. DOI: https://doi.org/10.1109/TASLP.2021.3122291

2. Baevski dkk. (2020) — Arsitektur Fondasi Wav2Vec 2.0 [5]: Memperkenalkan kerangka kerja *self-supervised* yang mengekstraksi fitur laten dari *raw waveform* menggunakan 7 lapisan CNN temporal, melakukan *masking* pada ruang laten, dan melatih Transformer menggunakan *contrastive task* terhadap representasi terkuantisasi (*codebook*). Studi ini membuktikan bahwa *fine-tuning* model SSL sangat efektif ketika data berlabel pada tugas hilir terbatas. DOI: https://doi.org/10.48550/arXiv.2006.11477

3. Yang dkk. (2025) — Multi-Feature Fusion & Attention pada Instrumen Tradisional [2]: Meneliti klasifikasi empat keluarga instrumen musik tradisional Tiongkok dengan menggabungkan tiga representasi spektral (MFCC, CQT, dan Chroma) ke dalam arsitektur CNN bermekanisme *Attention*, mencapai akurasi 98,79%. Studi

ini mengonfirmasi pentingnya gabungan informasi *timbre* dan *pitch* pada musik tradisional, meskipun fokusnya adalah instrumen tunggal dan bukan asal wilayah lagu polifonik. DOI: https://doi.org/10.3390/electronics14142805

4. Zhang dkk. (2025) — Transfer Learning Spektrogram dengan Pre-trained ZFNet [11]: Menggunakan arsitektur konvolusional pralatih ZFNet untuk mengekstraksi representasi fitur tingkat tinggi dari spektrogram visual audio guna mengklasifikasikan genre musik. Penelitian ini menunjukkan efektivitas *transfer learning* pada analisis musik, namun konversi ke citra 2D kehilangan informasi fase gelombang waktu. DOI: https://doi.org/10.1038/s41598-025-98766-7

5. Wang dkk. (2023) — Deformer (Denoising Transformer untuk Genre Musik) [3]: Mengusulkan model Deformer berbasis Transformer yang dilatih melalui tugas *denoising* dan rekonstruksi *patch* spektrogram sebelum di-*fine-tune* untuk klasifikasi genre musik, menghasilkan akurasi 84,5% dan mengungguli model pembanding. Studi ini memperkuat relevansi arsitektur *self-attention* dalam memodelkan hubungan temporal musik. DOI: https://doi.org/10.3390/app132312673

6. Luis & Rokhman (2022) dan Giri & Radhitya (2023) — Konteks Musik Tradisional Indonesia [1], [10]: Luis dan Rokhman (2022) mengklasifikasikan musik tradisional Indonesia dari 7 provinsi menggunakan rekaman YouTube, ekstraksi fitur MFCC, dan arsitektur CNN dengan akurasi 74,03% (https://doi.org/10.22146/ijccs.73910). Sementara itu, Giri dan Radhitya (2023) mengklasifikasikan lagu daerah menggunakan fitur akustik manual dan SVM dengan akurasi 73% (https://ojs.unud.ac.id/index.php/jnatia/article/view/104989). Kedua studi lokal ini membuktikan kelayakan pengenalan musik daerah Indonesia berbasis audio, tetapi masih mengandalkan fitur manual MFCC/statistik dan belum menguji model fondasi SSL *raw waveform*.

Tabel 1.1. Ringkasan Komparasi Penelitian Terdahulu dan Posisi State of the Art

Peneliti (Tahun)	Objek / Domain	Representasi Input	Metode / Arsitektur	Hasil Utama & Keterbatasan
Baevski dkk. (2020) [5]	Representasi Audio / Speech	1D Raw Waveform (16 kHz)	Wav2Vec 2.0 (CNN + Transformer Contrastive SSL)	Fondasi SSL waveform; belum diuji pada musik tradisional Nusantara.
Hsu dkk. (2021) [4]	Representasi Audio / Speech	1D Raw Waveform (16 kHz)	HuBERT (CNN + Transformer Masked k-Means SSL)	Stabilitas target klaster diskrit; adaptasi ke domain musik perlu pembuktian.
Luis & Rokhman (2022) [1]	Musik Tradisional Indonesia (7 Provinsi)	Koefisien MFCC 2D	Convolutional Neural Network (CNN)	Akurasi 74,03%; cakupan terbatas 7 provinsi & belum memakai model pretrained SSL.
Giri & Radhitya (2023) [10]	Lagu Daerah Indonesia	Fitur Akustik Handcrafted	Support Vector Machine (SVM)	Akurasi 73,00%; kehilangan struktur sekuensial waktu karena agregasi fitur statis.
Wang dkk. (2023) [3]	Klasifikasi Genre Musik	Patch Spektrogram Audio	Deformer (Denoising Transformer)	Akurasi 84,50%; berbasis rekonstruksi spektrogram, bukan raw waveform.
Yang dkk. (2025) [2]	Instrumen Tradisional Tiongkok (4 Kelas)	Fusi MFCC + CQT + Chroma	CNN + Multi-Feature Attention	Akurasi 98,79%; mengenali instrumen tunggal, bukan asal wilayah lagu daerah.
Zhang dkk. (2025) [11]	Klasifikasi Genre Musik	Citra Visual Spektrogram	Pre-trained ZFNet + Klasifikator	Menunjukkan manfaat transfer learning visual, namun bergantung pada resolusi STFT.
Penelitian Ini (Group 06, 2026)	Musik Tradisional Indonesia (38 Provinsi -> 7 Regional, 855 Lagu)	1D Raw Waveform 16 kHz Mono (5s / 80.000 sampel)	Komparasi Fine-Tuning Pre-trained HuBERT vs. Wav2Vec 2.0 + Class-Weighted Loss	Menguji head-to-head 2 model SSL waveform pada split tingkat lagu bebas leakage (Macro-F1).

Research Gap (Kesenjangan Penelitian):

Berdasarkan kajian literatur di atas, sebagian besar penelitian internasional mutakhir (Yang dkk., 2025; Zhang dkk., 2025; Wang dkk., 2023) berfokus pada klasifikasi genre musik umum atau kelompok instrumen tradisional Tiongkok berbasis spektrogram/fusi fitur, sedangkan penelitian pada konteks musik tradisional Indonesia (Luis & Rokhman, 2022; Giri & Radhitya, 2023) masih terbatas pada ekstraksi fitur manual MFCC dengan CNN atau SVM dari nol (*training from scratch*). Selain itu, perbedaan koleksi data, jumlah kelas, dan cara pembagian segmen membuat angka akurasi antar-penelitian tidak dapat dibandingkan secara langsung [9]. Penelitian ini mengisi kesenjangan tersebut dengan: (1) mengkurasi dataset primer 855 rekaman musik tradisional dari 38 provinsi yang dipetakan ke 7 klaster regional; (2) menerapkan *two-stage stratified split* pada tingkat lagu induk sebelum *chunking* untuk menjamin evaluasi bebas *data leakage*; serta (3) membandingkan secara langsung performa **Pre-trained HuBERT** dan **Wav2Vec 2.0** berbasis *1D raw waveform* menggunakan skema pembagian data, penanganan *class imbalance*, dan metrik Macro-F1 yang setara.

Data Acquisition, Preparation and Pre-processing

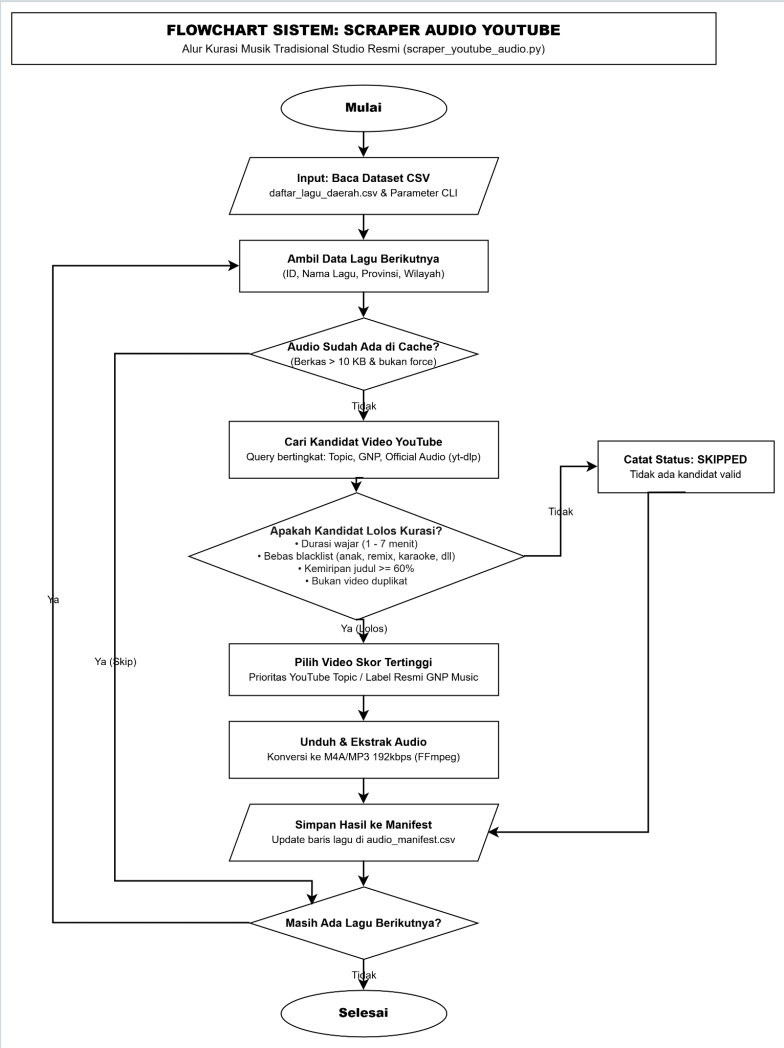
Must include (not limited to): data collection, data curation, data cleaning, data transformation, normalization, etc. (EDA).

1. Data Acquisition (Akuisisi & Kurasi Data Primer):

• **Sumber Data & Mekanisme Pengunduhan:** Koleksi audio merupakan data primer yang dikumpulkan secara terotomasi dari platform YouTube menggunakan skrip kurasi khusus *scraper_youtube_audio.py* berbasis pustaka *yt-dlp* dan *backend* multimedia *FFmpeg*. Tautan repositori dataset (audio sumber & hasil preprocessing): https://drive.google.com/drive/folders/1KSv0_nllF87kADHO6I5xPUZ02q7meFsl?usp=sharing

• **Protokol Kurasi & Filtering Ketat:** Diterapkan sistem penyaringan ketat berbasis ekspresi reguler (*blacklist regex*) guna mengeliminasi video musik anak-anak/kartun, aransemen *remix/jedag-jedug/koplo*, efek suara (SFX), dan konten non-lagu (berita, narasi cerita legenda, kompilasi *medley/nonstop*, serta paduan suara sekolah). Penelusuran memprioritaskan rekaman studio resmi (YouTube Topic, GNP Music, Gema Nada Pertiwi, Musica Studios, Aquarius Musikindo, Dasa Studio) dengan batas ambang kemiripan judul teks (*difflib*) ≥ 0,6 terhadap nama baku lagu daerah dan aturan ketat bahwa satu video hanya dialokasikan untuk satu lagu unik.

• **Format & Statistik Inventaris Asal:** Seluruh berkas audio tersimpan dalam format terkompresi **.m4a (AAC)** di bawah 38 subdirektori folder provinsi pada direktori *data/*. Hasil pemeriksaan *ffprobe* menghimpun total **855 berkas rekaman valid** dengan akumulasi durasi **3.675,85 menit (~61,28 jam)** dan ukuran kapasitas disk **4.477,60 MB (~4,37 GB)**. Sebanyak 37 provinsi berisi rekaman sedangkan 1 folder (*Papua_Pegunungan*) masih kosong. Sebanyak 572 rekaman memiliki *sample rate* 48.000 Hz dan 283 rekaman memiliki *sample rate* 44.100 Hz.



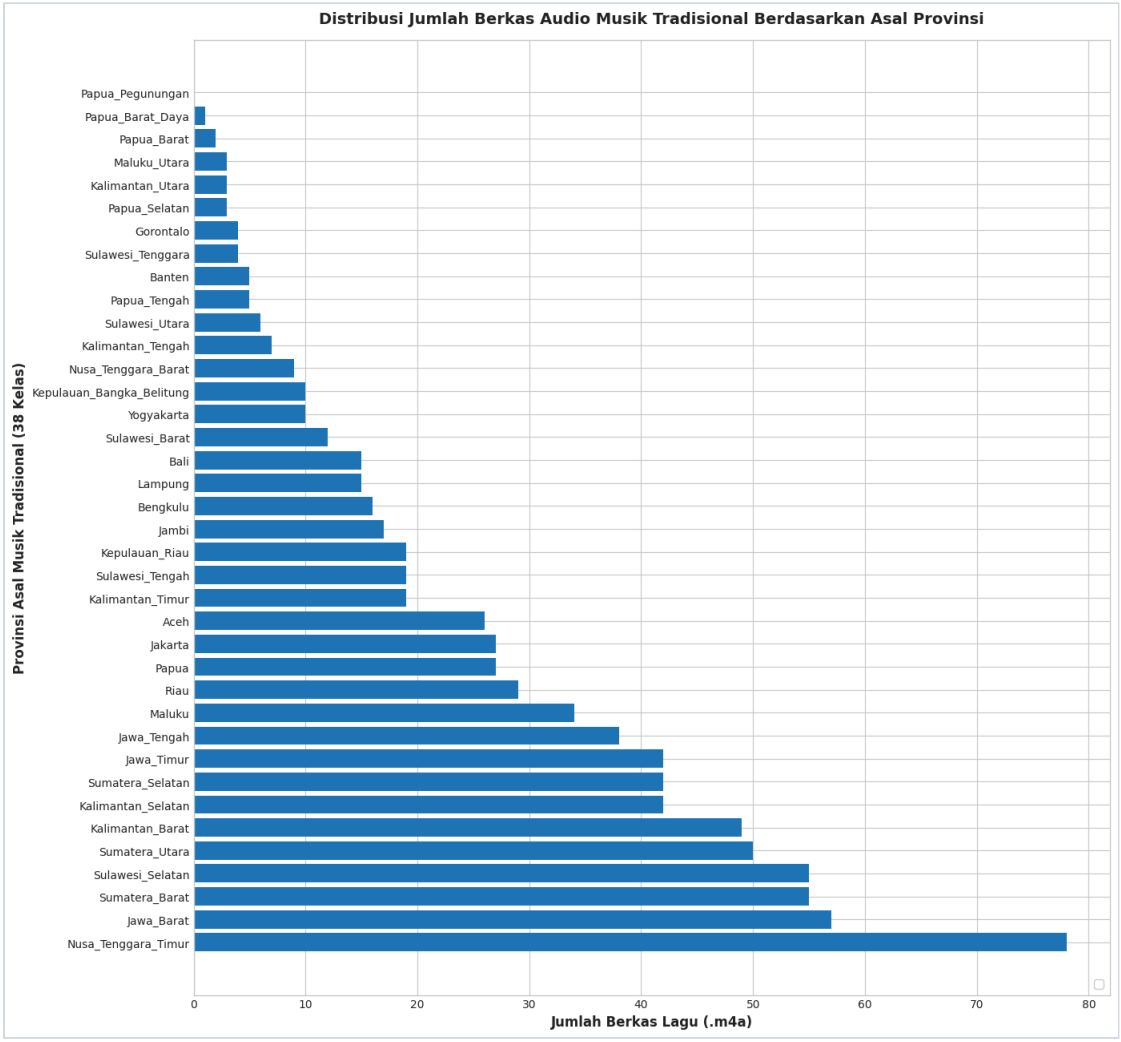
Gambar 2.1. Flowchart Sistem Akuisisi dan Kurasi Audio Musik Tradisional (scraper_youtube_audio.py)

2. Exploratory Data Analysis (EDA) & Visualisasi Karakteristik Dataset:

Analisis eksploratif dilakukan pada tingkat rekaman induk (855 berkas) maupun cuplikan sinyal untuk memahami distribusi geografis, variasi spesifikasi teknis, pencilan durasi, serta keterpisahan fitur akustik sebelum pemodelan. Sembilan variabel metadata sumber yang dicatat meliputi *file_path*, *provinsi*, *nama_file*, *ukuran_kb*, *durasi_detik*, *sample_rate*, *channels*, *codec*, dan *status*.

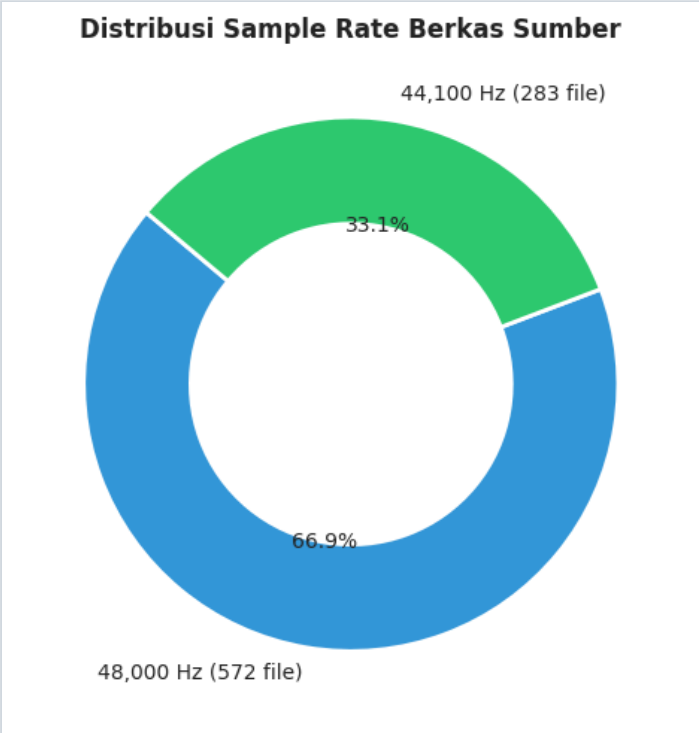
Tabel 2.1. Statistik Deskriptif Durasi Rekaman (855 Berkas) & Distribusi Kelas Regional

Metrik Durasi Audio	Nilai (Detik / Menit)	Klaster Regional Target	Jumlah Lagu	Proporsi (%)
Minimum (Min)	28,01 s (0,47 m)	1. Sumatera (10 Provinsi)	279 rekaman	32,63%
Kuartil Pertama (Q1)	182,79 s (3,05 m)	2. Jawa (6 Provinsi)	179 rekaman	20,94%
Median (Q2)	241,75 s (4,03 m)	3. Kalimantan (5 Provinsi)	120 rekaman	14,04%
Rata-rata (Mean)	257,95 s (4,30 m)	4. Bali–Nusa Tenggara (3 Prov.)	102 rekaman	11,93%
Kuartil Ketiga (Q3)	298,05 s (4,97 m)	5. Sulawesi (6 Provinsi)	100 rekaman	11,70%
Maksimum (Max)	1.854,02 s (30,90 m)	6. Papua (6 Provinsi)	38 rekaman	4,44%
Standar Deviasi & IQR	135,39 s | IQR: 115,26 s	7. Maluku (2 Provinsi)	37 rekaman	4,33%
Skewness (Kemiringan)	+4,09 (Positively Skewed)	Total Koleksi (Rasio 7,54 : 1)	855 rekaman	100,00%



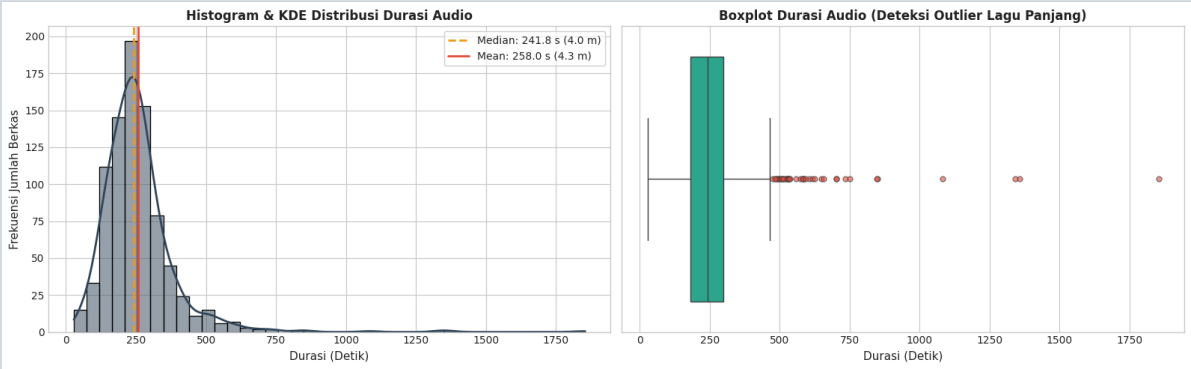
Gambar 2.2. Distribusi Jumlah Berkas Audio Musik Tradisional Berdasarkan Asal 38 Provinsi

Interpretasi Gambar 2.2 (Ketimpangan Provinsi & Bias Ketersediaan): Terlihat ketimpangan jumlah berkas yang tajam antardaerah: Nusa Tenggara Timur memiliki 78 rekaman dan Jawa Barat 57 rekaman, sedangkan 9 provinsi memiliki ≤ 5 rekaman (seperti Papua Barat Daya dengan 1 rekaman dan Papua Pegunungan 0 rekaman). Persebaran ini dipengaruhi ketersediaan dokumentasi daring di YouTube, bukan ukuran kekayaan musik daerah. Penggabungan ke 7 klaster regional menyelamatkan provinsi berlalulintas sampel sedikit tanpa membuang rekaman, meskipun dominasi sub-regional tetap ada (misalnya 78 dari 102 rekaman Bali–Nusa Tenggara berasal dari NTT). Hal ini mendasari penggunaan *class weights* dan pelaporan metrik evaluasi per kelas [8].



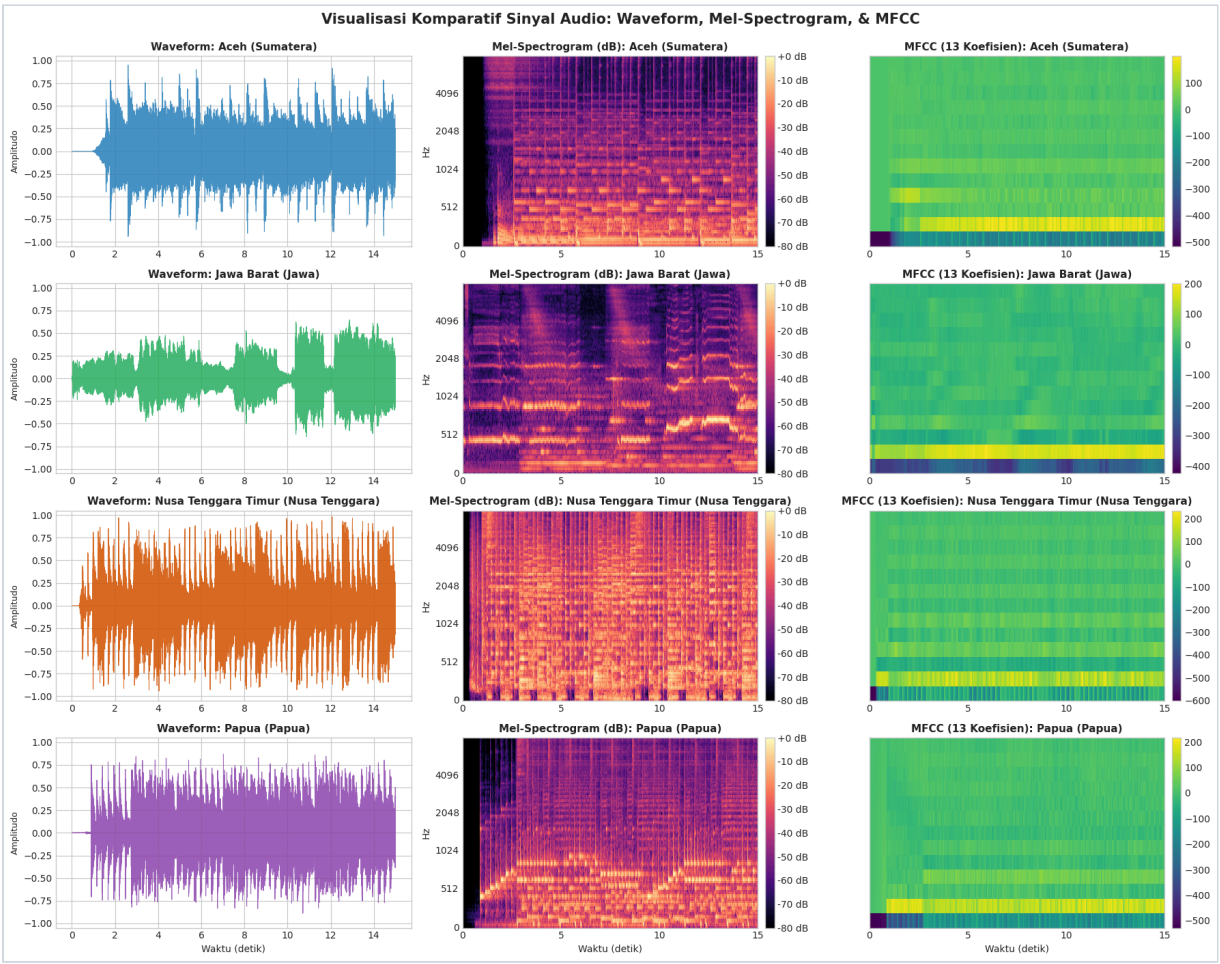
Gambar 2.3. Distribusi Frekuensi Sampel (Sample Rate) Berkas Audio Sumber

Interpretasi Gambar 2.3 (Variasi Teknis Sample Rate): Rekaman sumber terbagi ke dalam dua *sample rate* standar: 48.000 Hz sebanyak 572 berkas (66,9%) dan 44.100 Hz sebanyak 283 berkas (33,1%). Jika jaringan saraf memproses jumlah sampel tetap tanpa penyetaraan *sample rate*, durasi fisik dan skala frekuensi antar-rekaman akan menjadi tidak konsisten. Oleh sebab itu, seluruh rekaman diseragamkan ke **16.000 Hz mono** pada tahap preprocessing agar setiap segmen 5 detik tepat berisi 80.000 sampel sesuai spesifikasi arsitektur HuBERT dan Wav2Vec 2.0 [4], [5].



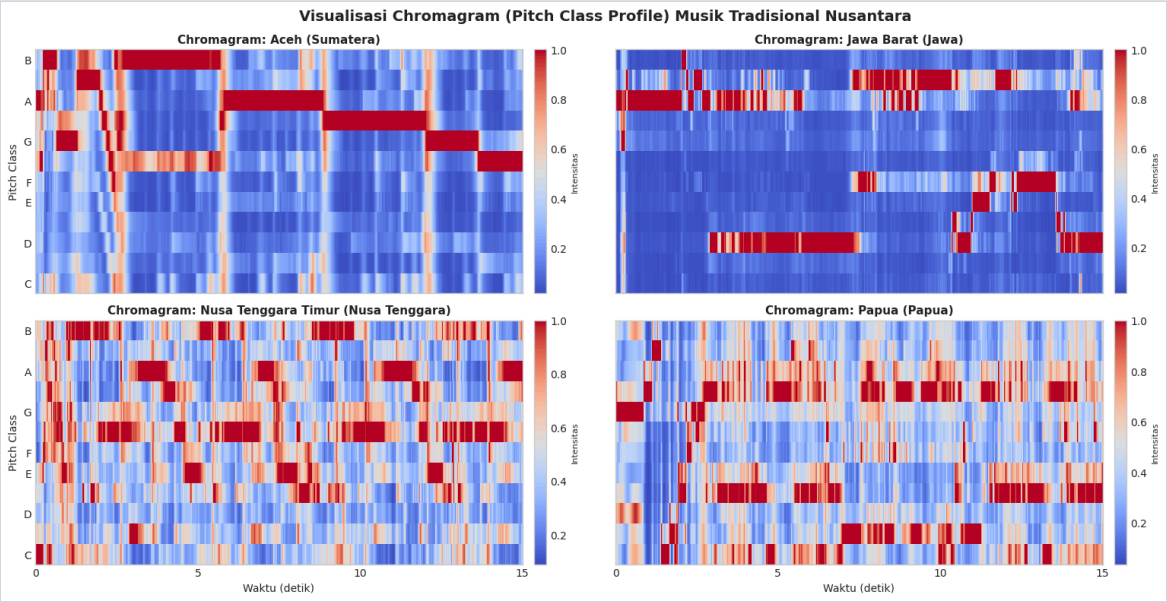
Gambar 2.4. Histogram & KDE Distribusi Durasi Audio serta Boxplot Deteksi Outlier Lagu Panjang

Interpretasi Gambar 2.4 (Distribusi Durasi & Risiko Dominasi Chunk): Separuh rekaman berada pada rentang 182,79–298,05 detik (3–5 menit), namun rata-rata (257,95 detik) melampaui median (241,75 detik) dengan *skewness* positif +4,09 akibat ekor distribusi kanan yang panjang. Boxplot mengidentifikasi sejumlah *outlier* rekaman pertunjukan panjang hingga maksimum 1.854,02 detik (30,90 menit). Pada segmentasi 5 detik, satu rekaman panjang menghasilkan ratusan *chunk* yang berisiko mendominasi optimasi dan evaluasi. Implikasinya, evaluasi model wajib menyertakan agregasi prediksi pada tingkat rekaman induk (*song-level evaluation*) agar banyak *chunk* dari satu lagu tidak dianggap sebagai bukti independen berlipat [9].



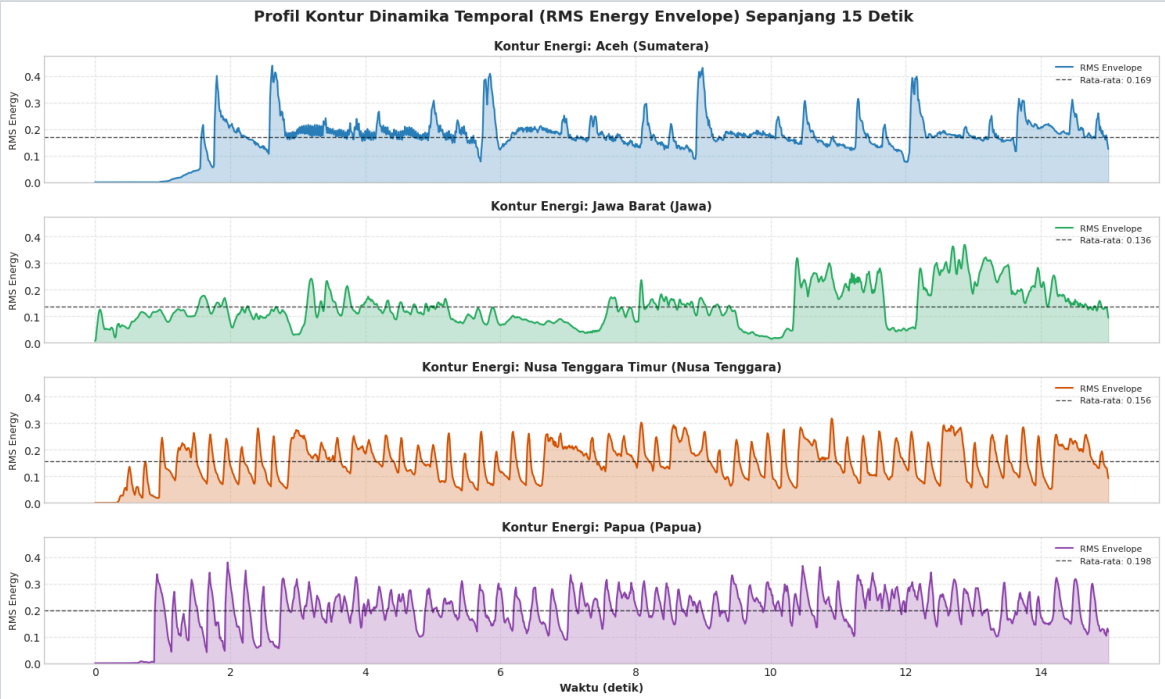
Gambar 2.5. Visualisasi Komparatif Multi-Domain: Waveform, Mel-Spectrogram, dan 13 Koefisien MFCC (4 Wilayah)

Interpretasi Gambar 2.5 (Komparasi Domain Waktu, Spektral Mel, dan Timbre MFCC): Pada keempat cuplikan 15 detik lintas zona budaya (Aceh/Sumatera, Jawa Barat/Jawa, NTT/Nusa Tenggara, dan Papua), terlihat perbedaan karakteristik yang saling melengkapi: Waveform Jawa Barat memperlihatkan dinamika amplitudo lembut dengan jeda frase vokal, NTT menampilkan puncak ritmis berulang, sedangkan Aceh dan Papua aktif secara kontinu. Mel-Spectrogram menampakkan pita harmonik horizontal dan ketukan transien vertikal yang tidak terlihat pada *waveform*, sementara MFCC merangkum perubahan selubung spektral (*timbre*) [2], [7]. Temuan ini mendukung pemanfaatan model sekuensial temporal (Transformer SSL) yang mampu mempelajari evolusi waktu–frekuensi langsung dari gelombang suara.



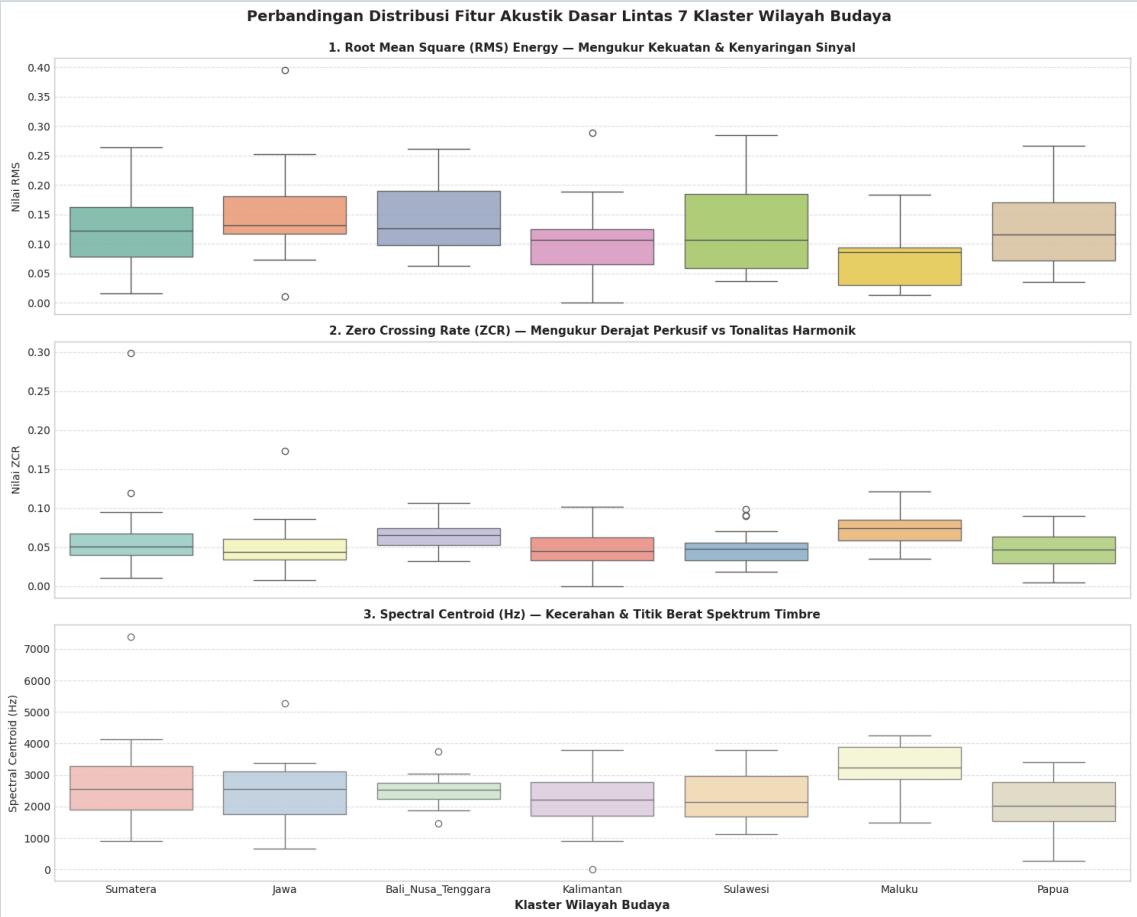
Gambar 2.6. Visualisasi Chromagram Berbasis Constant-Q Transform (Pitch Class Profile) 4 Wilayah Budaya

Interpretasi Gambar 2.6 (Distribusi Kelas Nada & Keterbatasan Grid Diatonis): Chromagram CQT memperlihatkan konsentrasi energi pada 12 kelas nada sepanjang waktu: cuplikan Aceh dan Jawa Barat memiliki pita nada dominan yang bertahan stabil dalam blok waktu (mencerminkan nada tumpu/*drone* melodi), sedangkan NTT dan Papua memperlihatkan perpindahan kelas nada yang lebih dinamis. Namun, karena Chromagram melipat informasi lintas oktaf ke dalam 12 *semitone* diatonis Barat, representasi ini berisiko mengalami kebocoran spektral pada laras non-diatonis (*salendro/pelog*) [7], sehingga ekstraksi fitur laten langsung dari *waveform* melalui CNN 1D pada HuBERT dan Wav2Vec 2.0 lebih fleksibel.



Gambar 2.7. Profil Kontur Dinamika Temporal (RMS Energy Envelope) Sepanjang 15 Detik

Interpretasi Gambar 2.7 (Kontur Energi RMS & Validasi Ambang Hening): Energi RMS berfluktuasi secara khas: Papua memiliki rata-rata RMS tertinggi (~0,203), Jawa Barat terendah (~0,141) dengan lembah jeda mencapai ~0,02, sementara Aceh menampilkan puncak transien sesaat tertinggi (> 0,40). Grafik ini sekaligus memvalidasi bahwa ambang penyaringan segmen hening **SILENCE_RMS_THRESHOLD = 0,001** berada jauh di bawah lembah frase musik lembut (~0,01–0,02), sehingga aman membuang bagian hening kosong (*dead air*) tanpa memotong bagian lagu yang pelan.



Gambar 2.8. Perbandingan Distribusi Fitur Akustik 1D (RMS, ZCR, Spectral Centroid) Lintas 7 Klaster Wilayah Budaya

Interpretasi Gambar 2.8 (Tumpang Tindih Fitur 1D & Justifikasi Deep Neural Network): Boxplot dari subset 140 rekaman lintas provinsi menunjukkan adanya pergeseran median (misalnya Maluku memiliki median ZCR dan Spectral Centroid lebih tinggi, serta terlihat korelasi positif antara ZCR dan Spectral Centroid), namun rentang antarkuartil ketujuh klaster wilayah budaya saling bertumpang tindih secara masif. Hal ini membuktikan bahwa satu nilai ringkasan fitur statistik 1D tidak mampu memisahkan kelas regional secara bersih, sekaligus memperkuat alasan digunakannya arsitektur **Deep Learning (HuBERT & Wav2Vec 2.0)** yang memodelkan representasi konteks temporal secara menyeluruh [4], [5], [8].

3. Data Preparation & Audio Pre-processing (Implementasi Pipeline & Hasil):

Berdasarkan temuan EDA, pipeline persiapan dan pemrosesan data diterapkan secara bertahap mulai dari tingkat rekaman induk (*song_id*) sebelum pemotongan segmen (*chunking*) guna menjamin tidak ada potongan dari lagu yang sama yang bocor lintas partisi *train*, *validation*, dan *test* [9]. Rincian parameter, justifikasi, dan hasil kuantitatif setiap tahap dirangkum pada Tabel 2.2 dan Tabel 2.3.

Tabel 2.2. Tahapan, Parameter Teknis, dan Justifikasi Pipeline Preprocessing Audio

Tahap Preprocessing	Proses & Parameter Teknis	Alasan Metodologis & Hasil
1. Identitas Unik (song_id)	Pembentukan song_id (<provinsi>__<nama_file>) & validasi assert is_unique pada 855 berkas.	Menghubungkan setiap berkas sumber dengan seluruh segmen WAV turunannya secara terlacak.
2. Agregasi Target Regional	Pemetaan 38 folder provinsi ke 7 klaster wilayah budaya (PROVINCE_TO_REGION).	Mempertahankan seluruh 855 lagu (0 lagu di-drop) dan mengatasi folder provinsi kosong/kritis (<5 lagu).
3. Stratified Song-Level Split	Two-stage stratified split (seed=42) pada level song_id: 70% Train, 15% Val, 15% Test.	Mencegah data leakage; menghasilkan 598 lagu Train, 128 lagu Val, dan 129 lagu Test (song_split.csv).
4. Konversi Mono & Resampling	Perataan kanal stereo menjadi mono (1 kanal) & resampling ke 16.000 Hz (torchaudio).	Menyeragamkan resolusi input 48 kHz & 44,1 kHz agar sesuai spesifikasi HuBERT & Wav2Vec 2.0 [4], [5].
5. Dynamic Overlap Chunking	Durasi 5 detik (80.000 sampel). Overlap Train: 50% (mayoritas) & 75% (minoritas <40 lagu: Maluku & Papua). Overlap Val/Test: 0%.	Memperbanyak variasi cuplikan kelas minoritas pada data latih sambil menjaga evaluasi Val/Test bebas duplikasi.
6. Zero-Padding & Silence Removal	Sisa ujung >= 50% (>= 2,5s) di-zero-pad; segmen dengan RMS < 0,001 dibuang otomatis.	Menjaga ukuran tensor tetap 80.000 sampel (90 chunk ter-pad) dan membuang 248 segmen hening kosong.
7. Ekspor WAV & Class Weights	Simpan WAV PCM_16, metadata.csv (78.074 chunk), dan hitung bobot w_c = N/(K*n_c) di class_weights.json.	Menyiapkan paket dataset bersih processed/ dan bobot Weighted Cross-Entropy Loss untuk memitigasi imbalance [8].

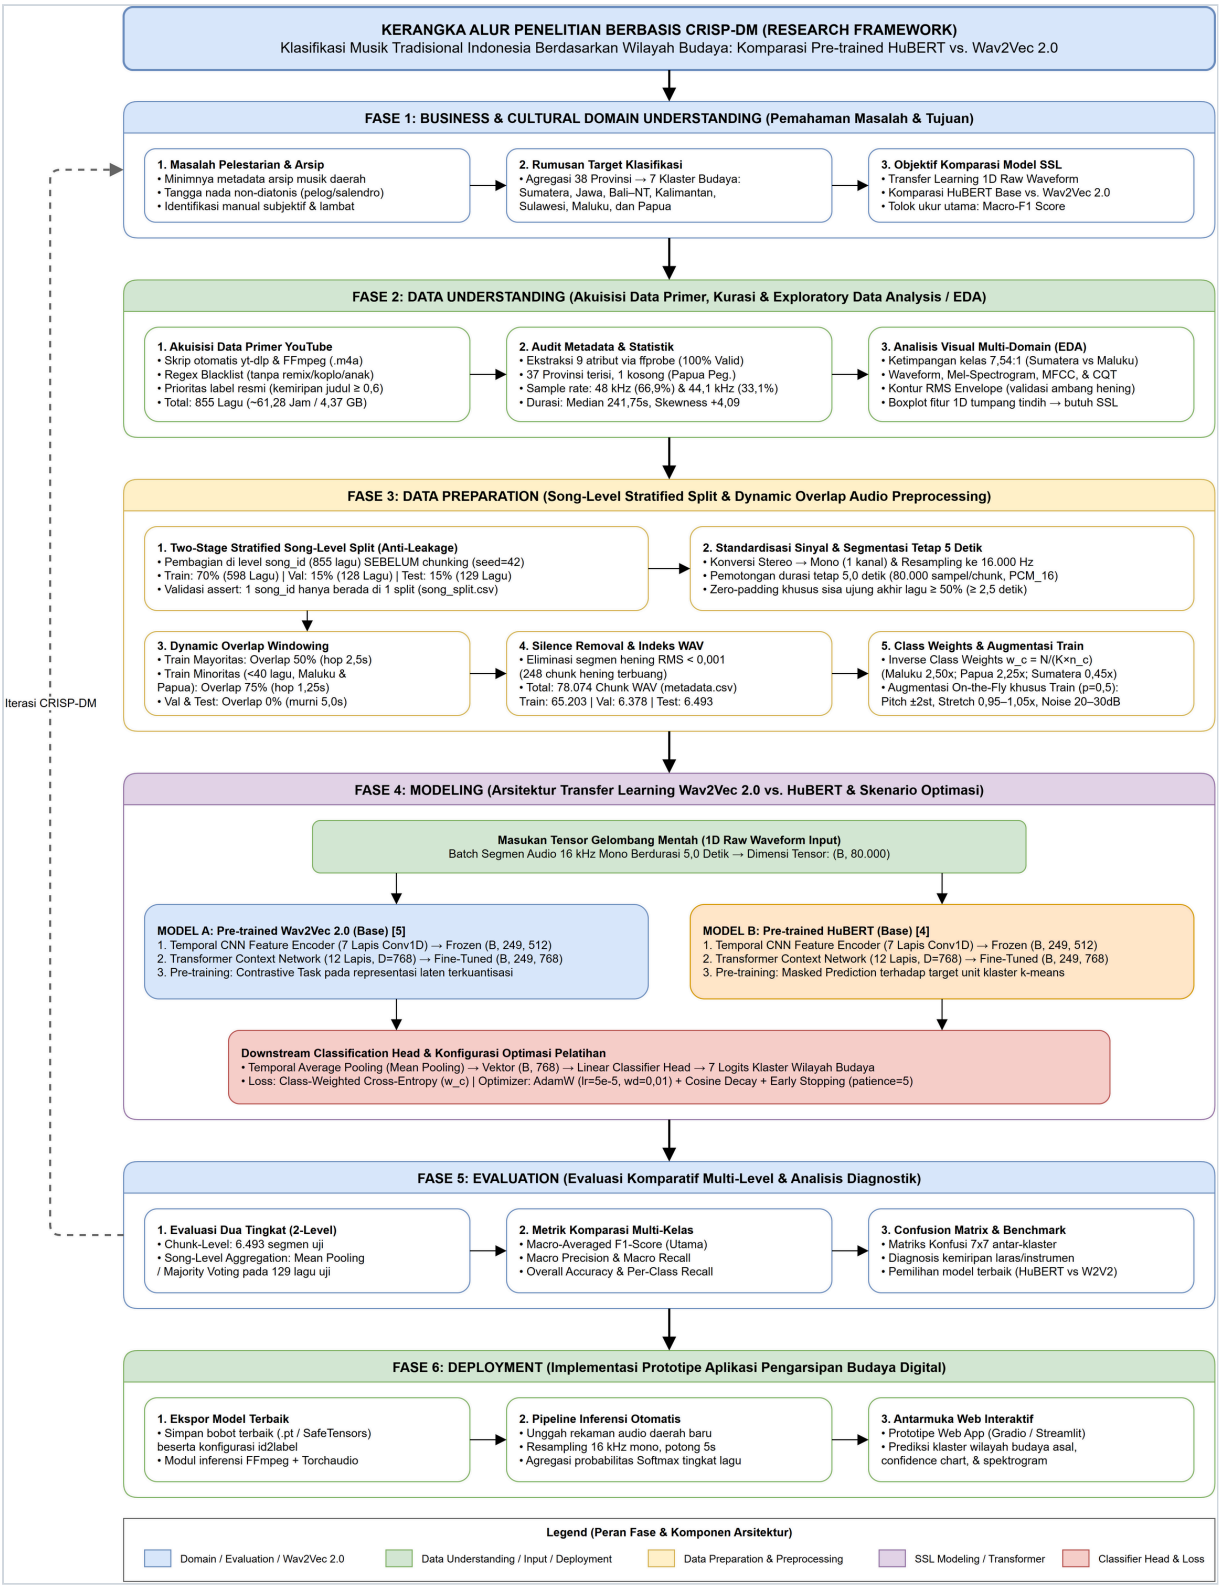
Tabel 2.3. Distribusi Rekaman Lagu Induk, Segmen Chunk WAV, dan Class Weights per Klaster Regional

Klaster Regional (Label)	Lagu Train	Lagu Val	Lagu Test	Total Lagu	Chunk Train	Chunk Val	Chunk Test	Class Weight (w_c)
Sumatera	195	42	42	279	20.849	2.133	2.160	0,4468
Jawa	125	27	27	179	12.347	1.339	1.333	0,7544
Kalimantan	84	18	18	120	8.220	784	893	1,1332
Bali_Nusa_Tenggara	71	15	16	102	7.858	919	757	1,1854
Sulawesi	70	15	15	100	8.068	709	846	1,1545
Papua (Minoritas, Overlap 75%)	27	6	5	38	4.142	235	261	2,2488
Maluku (Minoritas, Overlap 75%)	26	5	6	37	3.719	259	243	2,5046
Total Keseluruhan	598	128	129	855	65.203	6.378	6.493	Total: 78.074 Chunk

Methodology

Add research framework, and explain in details

Metodologi penelitian ini mengadopsi kerangka kerja standar **CRISP-DM (Cross-Industry Standard Process for Data Mining)** yang diintegrasikan dengan paradigma eksperimental komparatif *Transfer Learning* [6] pada model *Self-Supervised Learning* (SSL) audio. Pemilihan kerangka kerja CRISP-DM didasarkan pada sifat penelitian yang terstruktur dan berorientasi siklus penuh (*end-to-end lifecycle*), dimulai dari perumusan masalah domain pelestarian musik budaya Nusantara hingga tahap *deployment* prototipe aplikasi pengarsipan digital. Secara keseluruhan, kerangka kerja penelitian dibagi ke dalam **enam fase utama CRISP-DM** sebagaimana divisualisasikan pada Gambar 3.1:



Gambar 3.1. Kerangka Alur Penelitian (Research Framework) Berbasis 6 Fase CRISP-DM untuk Komparasi Pre-trained HuBERT vs. Wav2Vec 2.0

Fase 1: Business / Cultural Domain Understanding (Pemahaman Masalah & Tujuan Penelitian)

• **Perumusan Masalah Domain Budaya:** Mengidentifikasi kendala pengarsipan musik tradisional Indonesia yang masih tersebar tanpa metadata wilayah asal serta tingginya kompleksitas akustik instrumen etnik polifonik dan tangga nada non-diatonis (*pelog/salendro*) [1], [7].

• **Penetapan Sasaran Klasifikasi:** Mengarahkan tugas pemodelan pada pengenalan 7 klaster wilayah budaya regional Nusantara (Sumatera, Jawa, Bali–Nusa Tenggara, Kalimantan, Sulawesi, Maluku, dan Papua) agar seluruh provinsi tetap terwakili secara layak.

• **Kriteria Keberhasilan Teknis:** Membandingkan secara objektif dua model pralatih SSL (HuBERT vs. Wav2Vec 2.0) dengan metrik utama *Macro-Averaged F1-Score* baik pada tingkat segmen (*chunk-level*) maupun tingkat rekaman lagu utuh (*song-level*) [9].

Fase 2: Data Understanding (Akuisisi Data Primer & Exploratory Data Analysis / EDA)

• **Pengumpulan & Kurasi Rekaman Primer:** Mengumpulkan 855 berkas rekaman lagu daerah (.m4a, total durasi 61,28 jam / 4,37 GB) dari 38 folder provinsi melalui *yt-dlp* dan *FFmpeg* dengan penyaringan *blacklist regex* dan kurasi kemiripan judul ≥ 0,6.

• **Audit Metadata & Karakteristik Sinyal:** Mengekstrak 9 variabel metadata teknis menggunakan *ffprobe* serta memetakan distribusi kelas (rasio ketimpangan 7,54:1 antara Sumatera dan Maluku), proporsi *sample rate* (48 kHz vs. 44,1 kHz), dan sebaran durasi (*skewness* +4,09 dengan *outlier* hingga 30,90 menit).

• **Diagnosis Representasi Multi-Domain:** Menganalisis Waveform, Mel-Spectrogram, 13 MFCC, Chromagram CQT, RMS Envelope, dan Boxplot fitur akustik 1D (RMS, ZCR, Spectral Centroid) yang membuktikan perlunya pemodelan konteks temporal langsung dari gelombang suara [2], [7].

Fase 3: Data Preparation (Anti-Leakage Song-Level Splitting & Dynamic Overlap Preprocessing)

• **Two-Stage Stratified Song-Level Split:** Membagi 855 lagu induk (*song_id*) menggunakan *train_test_split* secara bertingkat dengan parameter *stratify* pada label klaster budaya dan *random_state=42* menjadi data latih (70% / 598 lagu), validasi (15% / 128 lagu), dan uji (15% / 129 lagu) sebelum proses pemotongan segmen, divalidasi dengan asersi (*assert*) anti-leakage.

• **Standardisasi & Dynamic Overlap Chunking (5 Detik / 80.000 Sampel):** Mengonversi seluruh audio menjadi mono 16 kHz (PCM_16) dan memotongnya menjadi segmen 5 detik. Partisi validasi dan uji dipotong tanpa tumpang tindih (0% overlap), sedangkan partisi latih menggunakan *dynamic overlap*: 50% overlap (hop 2,5 detik) untuk kelas mayoritas dan 75% overlap (hop 1,25 detik) untuk kelas minoritas (< 40 lagu: Maluku dan Papua). Sisa akhir lagu ≥ 50% diberi *zero-padding*.

• **Silence Filtering, Indeks Dataset, & Augmentasi On-the-Fly:** Mengeliminasi 248 segmen hening dengan RMS < 0,001 sehingga tersusun 78.074 *chunk* WAV bersih (65.203 train, 6.378 val, 6.493 test). Pada saat pelatihan, partisi data latih dilengkapi augmentasi *on-the-fly* (probabilitas 0,5) berupa *pitch shifting* (±2 semitone), *time stretching* (0,95–1,05x), dan penambahan *Gaussian background noise* (SNR 20–30 dB).

Fase 4: Modeling (Fine-Tuning Arsitektur Pre-trained Wav2Vec 2.0 vs. HuBERT)

• **Arsitektur Model A — Wav2Vec 2.0 (Base) [5]:** Terdiri atas 7 lapisan CNN *temporal feature encoder* dan 12 lapisan Transformer Encoder (dimensi tersembunyi 768) yang dilatih awal melalui *Contrastive Task* pada representasi laten terkuantisasi.

• **Arsitektur Model B — HuBERT (Base) [4]:** Memiliki struktur *backbone* setara (7 lapisan CNN temporal dan 12 lapisan Transformer 768 dimensi), namun dilatih awal melalui *Masked Prediction* terhadap target unit diskrit

hasil klasterisasi *k-means* (*pseudo-labels*).

• **Downstream Classification Head & Feature Freezing:** Pada kedua model, lapisan ekstraktor fitur CNN dibekukan (*frozen*) untuk menjaga kestabilan representasi akustik dasar, sedangkan 12 lapisan Transformer di-*fine-tune* secara adaptif. Keluaran sekuens Transformer diringkas menggunakan *Temporal Average Pooling* (*Mean Pooling*) menjadi vektor 768 dimensi, lalu dihubungkan ke *linear classifier head* menuju 7 kelas wilayah budaya.

• **Fungsi Loss Berbobot & Konfigurasi Optimasi:** Menerapkan *Class-Weighted Categorical Cross-Entropy Loss* dengan bobot frekuensi terbalik kelas (*w_c* dari *class_weights.json*) untuk memitigasi bias kelas mayoritas [8]. Pelatihan dioptimasi menggunakan AdamW (*learning rate* 5e-5, *weight decay* 0,01), penjadwalan *linear warm-up* dengan *cosine decay*, serta *Early Stopping* (*patience* 5 epoch) berbasis *validation loss*.

Fase 5: Evaluation (Evaluasi Komparatif Multi-Level & Analisis Diagnostik)

• **Evaluasi Dua Tingkat (Chunk-Level & Song-Level Aggregation):** Selain mengukur performa pada 6.493 segmen uji (*chunk-level*), prediksi probabilitas Softmax dari seluruh segmen milik satu *song_id* diagregasikan menggunakan *Mean Probability Pooling* dan *Majority Voting* untuk menghasilkan prediksi tingkat lagu utuh (129 lagu uji) agar lagu berdurasi panjang tidak mendominasi evaluasi [9].

• **Metrik Kinerja Multi-Kelas:** Mengukur *Accuracy*, *Macro-Averaged Precision*, *Macro-Averaged Recall*, dan *Macro-Averaged F1-Score* sebagai tolok ukur utama keandalan model di seluruh kelas (termasuk kelas minoritas Maluku dan Papua).

• **Analisis Confusion Matrix:** Memetakan matriks konfusi 7x7 untuk mendiagnosis pola kesalahan klasifikasi antar-wilayah budaya yang memiliki kemiripan instrumen atau tangga nada tradisional.

Fase 6: Deployment (Implementasi Prototipe Sistem Pengarsipan Musik Daerah)

• **Penyimpanan & Paketisasi Model Terbaik:** Model dengan capaian *Macro-F1* terbaik dari hasil evaluasi komparatif diekspor beserta konfigurasi pemetaan label (*id2label*) ke dalam modul inferensi terpadu.

• **Antarmuka Aplikasi Web Interaktif:** Mengimplementasikan prototipe aplikasi berbasis web (*Gradio / Streamlit*) yang memungkinkan pengguna mengunggah berkas rekaman audio musik tradisional, melakukan standardisasi dan pemotongan segmen 16 kHz mono secara otomatis di latar belakang, serta menyajikan hasil prediksi wilayah budaya asal beserta grafik tingkat keyakinan (*confidence score*) per klaster untuk mendukung dokumentasi budaya digital.

Results

Add screenshot of codes and results, or you can add notes like [the result refers to no. 1 in IPYNB "project_code"]

...

Evaluation

...

Deployment (if any)

...

Analysis and Discussion

Give your team depth analysis of the results, you may compare or benchmark with previous project/research.

...

References

[1] Luis, R., & Rokhman, N. (2022). Traditional music regional classification using convolutional neural network (CNN). *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, 16(4), 367–378. https://doi.org/10.22146/ijccs.73910

[2] Yang, J., Gao, F., Yun, T., Zhu, T., Zhu, H., Zhou, R., & Wang, Y. (2025). A deep-learning framework with multi-feature fusion and attention mechanism for classification of Chinese traditional instruments. *Electronics*, 14(14), Article 2805. https://doi.org/10.3390/electronics14142805

[3] Wang, J., Li, S., & Sung, Y. (2023). Deformer: Denoising transformer for improved audio music genre classification. *Applied Sciences*, 13(23), Article 12673. https://doi.org/10.3390/app132312673

[4] Hsu, W.-N., Bolte, B., Tsai, Y.-H. H., Lakhotia, K., Salakhutdinov, R., & Mohamed, A. (2021). HuBERT: Self-supervised speech representation learning by masked prediction of hidden units. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 29, 3451–3460. https://doi.org/10.1109/TASLP.2021.3122291

[5] Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 12449–12460. https://doi.org/10.48550/arXiv.2006.11477

[6] Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359. https://doi.org/10.1109/TKDE.2009.191

[7] Tzanetakis, G., & Cook, P. (2002). Musical genre classification of audio signals. *IEEE Transactions on Speech and Audio Processing*, 10(5), 293–302. https://doi.org/10.1109/TSA.2002.800560

[8] He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. https://doi.org/10.1109/TKDE.2008.239

[9] Sturm, B. L. (2014). The state of the art ten years after a state of the art: Future research in music information retrieval. *Journal of New Music Research*, 43(2), 147–172. https://doi.org/10.1080/09298215.2014.894533

[10] Giri, I. K. A. G., & Radhitya, I. G. N. A. (2023). Klasifikasi lagu daerah di Indonesia menggunakan ekstraksi fitur audio dan metode Support Vector Machine (SVM). *Jurnal Nasional Teknologi Informasi dan Aplikasinya (JNATIA)*, 1(4), 1065–1072. https://ojs.unud.ac.id/index.php/jnatia/article/view/104989

[11] Zhang, Y., dkk. (2025). Music genre classification using pre-trained ZFNet feature extraction on visual audio representations. *Scientific Reports*, 15, Article 98766. https://doi.org/10.1038/s41598-025-98766-7

AI Tools used for the project

...